

Gdy AI gubi się w realiach geopolitycznych: Anatomia krytycznego błędu "Knowledge Conflict"

Jak mechanizmy obronne stron WWW paraliżują wnioskowanie modeli językowych i prowadzą do dezinformacji.

W analizach wywiadowczych (OSINT) oraz w cyberbezpieczeństwie, precyzja nazewnictwa i ranga opisywanych podmiotów decydują o wszystkim. Jeden błąd potrafi zmienić lokalną prowokację w międzynarodowy kryzys dyplomatyczny. W dobie powszechnej automatyzacji i pisania raportów z pomocą sztucznej inteligencji, na jaw wychodzi fundamentalna, strukturalna podatność modeli LLM. Mowa o tzw. **Knowledge Conflict** (konflikcie wiedzy), który w połączeniu z blokadami sieciowymi może doprowadzić do krytycznych halucynacji.

Studium Przypadku: Incydent z Karolem Nawrockim

Podczas analizy zaawansowanego ataku hybrydowego na dom matki urzędującego **Prezydenta RP, Karola Nawrockiego** (polegającego na wysyłaniu fałszywych alarmów SMS-ami na numery dla głuchoniemych), model AI wygenerował hybrydę pojęciową, nazywając go "*prezesem IPN*". Dlaczego? Ponieważ w historycznych wagach modelu postać ta była mocno powiązana z dawną funkcją. Model zignorował bieżący kontekst geopolityczny i "skleił" dwie tożsamości, drastycznie obniżając rangę incydentu.

Anatomia błędu, czyli jak "myśli" model

Duże modele językowe (LLM) nie posiadają świadomości ani stałego, dynamicznego wglądu w otaczający świat. Ich wiedza opiera się na dwóch filarach:

- Wagi statyczne (Parametric Knowledge):** Wiedza nabyta podczas treningu pierwotnego. Przez lata Karol Nawrocki figurował w bazach danych jako historyk i prezes Instytutu Pamięci Narodowej. Ta informacja jest w modelu "wypalona" bardzo głęboko.
- Wiedza kontekstowa (Contextual Knowledge):** Informacje dostarczane na bieżąco przez użytkownika w prompcie lub pobierane na żywo z internetu za pomocą technologii RAG (Retrieval-Augmented Generation).

Gdy użytkownik wprowadza nową, przełomową informację (np. "Prezydent Karol Nawrocki"), wewnątrz sieci neuronowej dochodzi do konfliktu. Mechanizm uwagi (*Attention Mechanism*) próbuje powiązać stary, silny wektor semantyczny ("prezes IPN") z nowym wektorem ("Prezydent"). Jeśli model nie otrzyma twardego, zewnętrznego potwierdzenia, dochodzi do kompromisu logicznego – model "skleja" obie informacje, generując błąd dyskwalifikujący analizę.

Gdy tarcza anty-botowa oślepia sztuczną inteligencję

Dlaczego model po prostu nie sprawdził tego w sieci? Tutaj dochodzimy do drugiego, stricte technicznego problemu: **blokad parsowania stron internetowych**. Podczas próby weryfikacji faktów na portalu CyberDefence24.pl, systemy bezpieczeństwa serwera zwróciły błąd:

```
URL_FETCH_STATUS_ENP_BLOCKED
```

Współczesne portale informacyjne i rządowe stosują agresywne tarcze antyskrapingowe (np. Cloudflare, Incapsula), które traktują boty modeli językowych jak potencjalny atak DDoS lub próbę kradzieży treści. Efekt? Model zostaje "odcięty" od świeżego źródła prawdy (RAG). Nie mogąc sparsować zawartości artykułu pod linkiem, AI zostaje sam na sam ze swoim wewnętrznym konfliktem wiedzy.

Kontekst Realny (Fakt)	Halucynacja AI (Knowledge Conflict)
Atak hybrydowy na rodzinę Prezydenta RP – incydent najwyższego szczebla bezpieczeństwa państwa.	Atak na matkę prezesa IPN – incydent o niższej randze państwowej, traktowany jako lokalne zastraszenie.

Wnioski dla sektora Security & OSINT

Ten techniczny zgrzyt pokazuje, że ślepe zaufanie do systemów AI w analizie wywiadowczej to ogromne ryzyko. Aby przeciwdziałać takim podatnościom, systemy analityczne muszą wdrażać wieloźródłowy RAG, który nie poddaje się pojedynczym blokadom serwerów. Dla analityka wniosek jest jeden: weryfikacja nomenklatury i funkcji kluczowych person w państwie zawsze musi podlegać ostatecznej, ludzkiej autoryzacji (Human-in-the-loop). W przeciwnym razie, mechanizmy obronne stron www paradoksalnie staną się narzędziem ułatwiającym dezinformację.